INSTITUTO
UNIVERSITÁRIO
DE LISBOA

Descoberta e Extração de Conhecimento de Dados

2º Semestre, 2025/2026

Projeto Final

> Este projeto foi concebido para ser resolvido em grupo, constituídos por 3, **4** (recomendado), **5** (recomendado) ou 6 estudantes. Cada um dos elementos do grupo deverá inscrever-se, através do moodle, num dos grupos disponíveis para realização do Projeto. O trabalho deverá também ser entregue através do moodle, devendo o grupo fazer duas entregas ao longo da sua execução, em datas distintas, pré-definidas, e indicadas abaixo. A 1ª entrega corresponde ao trabalho desenvolvido na Parte 1 e a 2ª entrega corresponde à entrega final e deverá descrever todo o trabalho desenvolvido. Cada entrega deverá consistir num ficheiro `.zip` contendo um relatório escrito em formato `.pdf`, bem como o código (*notebook(s)* ou código Python) desenvolvido.
> O relatório deverá descrever o trabalho desenvolvido e reportar os resultados obtidos. Neste relatório é fundamental descrever os principais passos do ciclo de desenvolvimento, nomeadamente: compreensão do problema, compreensão dos dados, preparação dos dados, modelação (extração de padrões e predição), avaliação e, por fim, conclusões. As escolhas tomadas devem ser adequadamente justificadas, devendo incluir, sempre que necessário, gráficos ou tabelas. O relatório deve conter a identificação do grupo e dos seus membros no início da primeira página. Na última secção do relatório deve ser indicada uma estimativa da percentagem de contribuição de cada elemento para o trabalho, juntamente com uma pequena explicação. Por exemplo: manuel: 30%, mariana: 30%, joaquim: 40%.
> *É obrigatório fazer uma apresentação oral do projeto.*
> **Entrega da 1ª parte:** 24 de abril de 2026
> **Entrega da 2ª parte:** 23 de maio de 2026
> **Apresentação:** 25 a 29 de maio de 2026

Este projeto foca-se na aprendizagem prática do ciclo de vida da Ciência de Dados, utilizando a metodologia CRISP-DM como estrutura fundamental para o desenvolvimento de soluções de descoberta e extração de conhecimento de dados.

O objetivo principal é abordar o problema do risco de doenças cardiovasculares atra-

vés da utilização de abordagens supervisionadas para a previsão de risco e de abordagens não supervisionadas para a identificação de padrões ou perfis de saúde. Para o efeito, deverá ser utilizado um conjunto de dados baseado no Behavioral Risk Factor Surveillance System[1] [Lupague et al., 2023]. Este sistema de vigilância realiza inquéritos telefónicos aos residentes dos vários estados dos EUA, recolhendo dados relacionados com a saúde, no que diz respeito a comportamentos de risco, doenças crónicas e utilização de serviços preventivos.

O projeto e o relatório devem seguir as fases da metodologia CRISP-DM.

Para realizar as experiências com os diferentes modelos de aprendizagem automática, deve ser utilizado o conjunto de ferramentas scikit-learn[2] [Pedregosa et al., 2011].

Dados

Este conjunto de dados [Lupague et al., 2023], obtido a partir do inquérito anual de 2021 do Behavioral Risk Factor Surveillance System pelo Center for Disease Control and Prevention, continha originalmente 438.693 registos com 304 atributos. No entanto, com o objetivo de construir um modelo preditivo de aprendizagem automática para doenças cardiovasculares, foi selecionado um subconjunto constituído por 19 atributos relevantes. Este processo de seleção reduziu o conjunto de dados para 308.854 registos, que deverão ser utilizados para diferentes análises e desenvolvimento dos modelos.

Cada objeto de dados é caracterizado pelas seguintes 19 variáveis:

General Health | Saúde Geral Diria que, de uma forma geral, a sua saúde é …

Checkup | Checkup Há quanto tempo foi a sua última consulta de rotina num médico?

Exercise | Exercício Físico Durante o último mês, além do seu trabalho regular, participou em atividades físicas ou exercícios como corrida, calistenia, golfe, jardinagem ou caminhada?

Heart Disease | Doença Cardíaca Inquiridos que reportaram ter doença coronária ou enfarte do miocárdio.

Skin Cancer | Cancro de Pele Inquiridos que reportaram ter tido cancro de pele.

Other Cancer | Outro Cancro Inquiridos que reportaram ter tido qualquer outro tipo de cancro.

Depression | Depressão Inquiridos que reportaram ter um distúrbio depressivo (incluindo depressão, depressão major, distimia ou depressão minor).

Diabetes | Diabetes Inquiridos que reportaram ter diabetes. Em caso afirmativo, qual o tipo de diabetes.

[1] `https://www.cdc.gov/brfss/annual_data/annual_2021.html`
[2] `https://scikit-learn.org/stable/index.html`

Arthritis | Artrite Inquiridos que reportaram ter artrite.

Sex | Sexo Sexo do inquirido.

Age Category | Escalão Etário Categoria etária do inquirido.

Height | Altura Altura do inquirido em cm.

Weight | Peso Peso do inquirido em kg.

BMI | IMC Índice de massa corporal do inquirido.

Smoking History | Histórico de Tabagismo Se o inquirido tem histórico de consumo de tabaco.

Alcohol Consumption | Consumo de Álcool Dados autorreportados relativos à frequência e quantidade de ingestão de álcool pelo inquirido.

Fruit Consumption | Consumo de Fruta Dados autorreportados relativos à frequência e quantidade de ingestão de fruta pelo inquirido.

Green Vegetables Consumption | Consumo de Legumes Verdes Dados autorreportados relativos à frequência e quantidade de ingestão de vegetais de folha verde pelo inquirido.

Fried Potato Consumption | Consumo de Batatas Fritas Dados autorreportados relativos à frequência e quantidade de ingestão de batatas fritas pelo inquirido.

De notar que, na etapa de Data Understanding da metodologia CRISP-DM, estes aspetos devem ser claramente abordados, proporcionando uma compreensão adequada destes dados.

O conjunto de dados está disponível em `moodle.iscte-iul.pt`.

Parte 1: Exploração Inicial

Esta parte do trabalho foca-se nas fases iniciais do CRISP-DM.

Compreensão do Problema

Nesta fase devem ser discutidas quais as perguntas a que o trabalho deve responder, nomeadamente, sob que perspetiva vão ser analisados os ***clusters*** que resultarão das abordagens não supervisionadas e quais as **variáveis alvo**/***targets*** mais adequadas ao problema. Por exemplo, variáveis alvo interessantes para problemas de classificação incluem o diagnóstico de diabetes ou de doença cardiovascular. Por outro lado, as abordagens não supervisionadas, neste contexto, podem conduzir a análises muito relevantes através da identificação de diferentes perfis.

Na segunda parte do trabalho, como o CRISP-DM além de iterativo estabelece saltos entre fases não consecutivas, é sempre possível revisitar esta fase e redefinir o problema.

Prazo recomendado: 2 de abril de 2026

Compreensão dos Dados

Nesta fase, para além dos dados, deve ser usada a informação que se encontra nas páginas da coleção de forma a compreender adequadamente as suas propriedades.

Embora o BRFSS seja disponibilizado como um único ficheiro, contém variáveis de naturezas distintas: sociodemográficas, comportamentais, de acesso a cuidados e de condições de saúde. É essencial compreender esta estrutura para selecionar adequadamente as variáveis preditoras e evitar incluir informação redundante ou identificadores que não têm valor preditivo. Pode ser interessante e útil ter em conta outras fontes de informação que possam enriquecer a análise, desde que a integração seja feita de forma consistente e sem introduzir enviesamentos.

Aqui devem ser explorados diferentes métodos de compreensão de dados, incluindo diferentes tipos de visualizações. Devem ser analisadas as várias variáveis (*features*), correlações entre estas, descritos os detalhes mais relevantes, e analisados diferentes aspetos relativos à qualidade dos dados, incluindo *outliers*.

Prazo recomendado: 10 de abril de 2026

Preparação dos Dados

Nesta fase devem ser exploradas diferentes versões dos dados.

Se necessário, deve começar-se por implementar uma estratégia para lidar com elementos de valor nulo. Depois, o conjunto de dados deve ser processado de duas formas, sempre justificando as suas opções:

1. criando um conjunto de dados completamente categórico;
2. criando um conjunto de dados completamente numérico.

Por fim, devem ser exploradas duas formas diferentes de normalizar os dados. O relatório deve descrever cada um dos métodos e as principais diferenças relativamente aos dados produzidos.

Para compreender o impacto das várias experiências devem ser exploradas diferentes visualizações dos dados.

Prazo recomendado: 15 de abril de 2026

Modelação usando Abordagens não Supervisionadas

Nesta fase deve ser explorados diferentes métodos de *clustering*: k-*means* (qual o impacto do k? qual o impacto da normalização?), *clustering* hierárquico (onde deve ficar o corte do dendrograma?) e DBSCAN (qual o impacto de diferentes escolhas para os parâmetros?).

Para se compreender os resultados, deve tirar-se partido de diferentes visualizações e da caracterização de alguns *clusters*, incluindo exemplos. Esta avaliação devem ser complementada por métricas adequadas à avaliação deste tipo de métodos.

Prazo recomendado: 20 de abril de 2026

Parte 2

Tal como indicado anteriormente, o CRISP-DM além de iterativo estabelece possibilita o regresso a fases anteriores, pelo que pode ser interessante, nesta altura, revisitar essas fases e melhorar o trabalho realizado.

Modelação usando Abordagens Supervisionadas

Nesta fase devem ser explorados diferentes métodos de classificação e/ou regressão, de acordo com os *targets* definidos previamente. É importante explorar diferentes preparações dos dados, bem como diferentes parametrizações dos métodos supervisionados.

Na avaliação deve ter-se o cuidado de aplicar as métricas adequadas, garantindo ter uma boa perceção dos resultados (diferentes métricas, possibilitam diferentes perspetivas). Estes devem ser analisados cuidadosamente e se necessário, deve regressar-se às fases de preparação e compreensão dos dados até que se tenham alcançado os melhores resultados possíveis.

Prazo recomendado: 13 de maio de 2026

Avaliação

Nesta fase deve fazer uma análise crítica dos resultados indicando se estes respondem adequadamente aos objetivos colocados nas fases iniciais. Serão realmente úteis? É possível usar o conhecimento que resultou da modelação para resolver o problema?

Prazo recomendado: 19 de maio de 2026

Relatórios

Os relatórios devem estar em formato `.pdf` e não deverão ultrapassar as 15 páginas, indicando o que é importante ou relevante. Podem, no entanto, usar anexos para material

complementar que achem necessário disponibilizar.

No caso dos gráficos descritivos de distribuições de dados, os importantes para suportar o que é descrito no texto principal (por exemplo, os que ilustram a quantidade de observações em cada classe de uma variável/atributo alvo) devem ser colocados perto do sítio no texto onde são referidos (e não em anexo).

Os relatórios devem sempre terminar com uma secção onde se destacam os aspetos mais importantes do trabalho, quais os próximos passos/trabalho futuro e quais as principais limitações. Tal como indicado anteriormente, nesta secção deve ser indicada uma estimativa da percentagem de contribuição de cada elemento para o trabalho, juntamente com uma pequena explicação. Por exemplo: manuel: 30%, mariana: 30%, joaquim: 40%.

Apresentação

O grupo deverá também fazer uma apresentação (presencial), com uma duração de 10 minutos (máximo), que deve mencionar os pontos mais importantes do trabalho. Deverá abordar o problema que estão a resolver, a *descrição dos dados* utilizados no trabalho, as *experiências mais relevantes*, os *resultados mais interessantes/importantes*. No final da apresentação serão colocadas perguntas aos elementos do grupo.

A não realização da apresentação implica uma nota final do projeto de 0 valores.

Referências

R. M. J. M. Lupague, R. C. Mabborang, A. G. Bansil, and M. M. Lupague. Integrated machine learning model for comprehensive heart disease risk assessment based on multidimensional health factors. *European Journal of Computer Science and Information Technology*, 11(3):44–58, 2023.

F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.

Política em caso de fraude

Os estudantes podem partilhar e/ou trocar ideias entre si sobre os trabalhos e/ou resolução dos mesmos. No entanto, o trabalho entregue deve corresponder ao esforço individual de cada grupo. As seguintes situações são consideradas fraudes:

- Trabalho parcialmente copiado;
- Facilitar a copia através da partilha de ficheiros;
- Utilizar material alheio sem referir a sua fonte.

Em caso de deteção de algum tipo de fraude, os trabalhos em questão não serão avaliados, sendo enviados à Comissão Pedagógica ou ao Conselho Pedagógico, consoante a gravidade da situação, que decidirão a sanção a aplicar aos alunos envolvidos. Serão utilizadas as ferramentas Moss e SafeAssign para deteção automática de cópias.

Recorda-se ainda que o Anexo I do Código de Conduta Académica, publicado a a 25 de Janeiro de 2016 em Diário da Republica, 2ª Série, nº 16, indica no seu ponto 2 que:

> Quando um trabalho ou outro elemento de avaliação apresentar um nível de coincidência elevado com outros trabalhos (percentagem de coincidência com outras fontes reportada no relatório que o referido software produz), cabe ao docente da UC, orientador ou a qualquer elemento do júri, após a análise qualitativa desse relatório, e em caso de se confirmar a suspeita de plágio, desencadear o respetivo procedimento disciplinar, de acordo com o Regulamento Disciplinar de Discentes do ISCTE - Instituto Universitário de Lisboa, aprovado pela deliberação n.o 2246/2010, de 6 de dezembro.

O ponto 2.1 desse mesmo anexo indica ainda que:

> No âmbito do Regulamento Disciplinar de Discentes do ISCTE-IUL, são definidas as sanções disciplinares aplicáveis e os seus efeitos, podendo estas variar entre a advertência e a interdição da frequência de atividades escolares no ISCTE-IUL até cinco anos.